研究报告 · 2026 年 11 月

订阅套餐 vs API 按量计费：同样的 token 值多少钱

Claude Pro / Max、ChatGPT Pro（Codex）等订阅用满时折合的 API 价，以及 Opus 5.5 在 Amazon Bedrock 上的对应成本

数据截至 2026-10-30 · 金额单位：美元（USD）· 1 亿 token = 100M token · 「API 等值」指把订阅用满一个月消耗的 token 按 API 标价计算的金额

Claude Pro（Opus 5.5）	Claude Max 20x（Opus 5.5）	ChatGPT Pro $200（Codex）	Cursor 里用 Claude / GPT
$1,178	**$11,726**	**$2,084**	**1 倍**
每月 API 等值，月费 $20 的 59 倍；Bedrock 区域端点 $1,296	每月 API 等值，月费 $200 的 59 倍	GPT-6.1 Sol，10.4 倍；GPT-6 Astra $2,897（14.5 倍）	按 API 标价付费，没有补贴

核心结论

1. **Claude Pro 用满一个月 Opus 5.5，同样的 token 放到 Bedrock 上约 $1,178，是月费的 59 倍。**
   按编码 Agent 的典型负载，Pro 用满约 25–30 亿 token/月，其中约 97% 是缓存读。Bedrock global 端点约 $1,178；区域端点贵 10%，约 $1,296（65 倍）。按真实用户的混合流量实测，约 $680/月（34 倍）。（证据：§1 表 1、§2 表 3、§3 表 6）

2. **Bedrock global 端点与 Anthropic 官方 API 完全同价，区域端点贵 10%。**
   AWS 公开价目表中，Opus 5.5 在 global 端点的输入、输出、两种缓存写、缓存读五项价格与官方一致；非 global 端点全部 ×1.1。所以把订阅的用量换到 Bedrock 上跑，成本就是官方 API 成本，或再乘 1.1。（证据：§1 表 1）

3. **Claude 各档每美元价值相同（57–59 倍）；Max 的 5x / 20x 只指 5 小时窗口。**
   Max 5x 约 $5,725/月，Max 20x 约 $11,726/月。按周额度算，Max 5x 和 Max 20x 分别约为 Pro 的 4.9 倍和 10 倍，所以升级 Max 换来的是更高的用量上限，每美元的价值并不会更高。（证据：§2 表 3、图 1）

4. **ChatGPT Pro $200（Codex）用满约 $2,084/月 的 GPT-6.1 Sol（10.4 倍），或 $2,897/月 的 GPT-6 Astra（14.5 倍）。**
   9 月 29 日起新订阅的 Pro $200 额度下调，老用户保留旧额度到 10 月 29 日；10 月 30 日起全部按新额度。同价位的中档模型上，Claude 订阅的 API 等值约为 ChatGPT 的 5.5 倍；旗舰模型（Fable 5.1 对 GPT-6 Astra）两家接近，都在 12–15 倍。（证据：§2 表 5、图 1）

5. **订阅真正限制的是非缓存 token：Claude Pro 约 1 亿/月，Max 20x 约 8–10 亿，ChatGPT Plus 约 3,000 万。**
   两个独立来源（SemiAnalysis 数据反推、Wokey 真实账号实测）在这一点上的差距在约 20% 以内。（证据：§3 图 2）

6. **倍数这么大，是因为缓存读在订阅里几乎不计额度，而 API 对它照样收费。**
   编码 Agent 的 token 有 96.6% 是缓存读，Claude Pro 的 $1,178 里约一半是缓存读的钱。负载越偏 Agent（长上下文、反复读缓存）越划算；纯聊天时 Max 20x 只有 46 倍。（证据：§4 表 7、图 3）

7. **第三方工具和其他订阅没有这么高的补贴。**
   在 Cursor 里用 Claude / GPT 按 API 标价计费（1 倍）；中国厂商的 coding plan 平均略低于 12 倍；Google 不公布额度，也没有可靠实测。（证据：§5 表 8）

阅读提示：以上数字是「每周都把额度用满」时的上限，全部来自第三方实测。厂商不公布额度，还会调整和做 A/B 测试； 改成按量付费后，人通常会少用、换更便宜的模型，所以实际能省下的钱比这些倍数小。详见 §6。

数据来源与口径

- **官方价格：**Anthropic 定价页；AWS 公开的 Price List API（`AmazonBedrockFoundationModels`，us-east-1，2026-10-12 版）；OpenAI API 定价页。
- **SemiAnalysis（2026-10-05）：**用付费账号逐类灌入 token（输入、缓存写、缓存读用《战争与和平》节选，输出用技术文章），读取额度计量条的变化，测到误差 ±5% 以内； 灌入 5 亿缓存读 token 后计量条仍不动，就把缓存读按免费处理。再按其 9 月统计的负载结构，用 API 价折算成美元。原文在付费墙后，本报告的数字取自三篇公开转述，三处一致。
- **Wokey（2026-10-19 至 10-26）：**网关后真实订阅账号的流量。当某账号的周额度上涨 10 个百分点以上时，用这段时间的请求量推算整周用量，先取每个账号的中位数，再取账号间的中位数，按官方 API 价计价。
- **本报告的推算：**「约合 token/月」由 API 等值 ÷ 加权单价反推（附录 A），区间下限按长 TTL 缓存写计，上限按短 TTL 计。

§1 API 单价：Bedrock global 与官方 API 同价

表 1 · Opus 5.5 单价（美元 / 百万 token）

渠道	输入	缓存写（5 分钟）	缓存写（1 小时）	缓存读	输出
Anthropic 官方 API	$4.00	$5.00	$8.00	$0.20	$20.00
Bedrock global 端点	**$4.00**	**$5.00**	**$8.00**	**$0.20**	**$20.00**
Bedrock 区域 / geo 端点	**$4.40**	**$5.50**	**$8.80**	**$0.22**	**$22.00**
官方 API 指定 `inference_geo: "us"`	$4.40	$5.50	$8.80	$0.22	$22.00
参考：Sonnet 5.5，Bedrock global	$2.00	$2.50	$4.00	$0.10	$10.00

- AWS 价目表中 Opus 5.5 的计费项：`USE1_input_tokens_global_standard` = $4.00，`USE1_input_tokens_standard` = $4.40； 输出 $20.00 / $22.00；缓存写 $5.00 / $5.50（5 分钟）、$8.00 / $8.80（1 小时）；缓存读 $0.20 / $0.22。后者是非 global 端点，五项都正好 ×1.1。
- Anthropic 定价页写明：对 Claude 4.5 及以后的模型，Bedrock 的区域和多区域端点比 global 端点贵 10%；在官方 API 上指定 `inference_geo: "us"` 同样 ×1.1。
- Opus 5.5 的缓存读只收输入价的 0.05 倍（多数模型是 0.1 倍），完整 1M 上下文不加价。与 Opus 5（$5 / $25）相比，输入和输出降价 20%，缓存读降价 60%。

表 2 · OpenAI 模型单价（美元 / 百万 token，上下文 ≤272K）

模型 / 渠道	输入	缓存写（30 分钟）	缓存写（12 小时）	缓存读	输出
GPT-6.1 Sol：OpenAI API	$2.00	$2.50	$5.00	$0.10	$10.00
GPT-6 Astra：OpenAI API	$10.00	$12.50	$25.00	$1.00	$50.00
GPT-6 Astra：Bedrock global 端点	$10.00	$12.50	—	$1.00	$50.00
GPT-6 Astra：Bedrock 区域端点	$11.00	$13.75	—	$1.10	$55.00

- 上下文超过 272K 时，OpenAI 的输入价约 ×2、输出价约 ×1.5；OpenAI 的区域处理（数据驻留）端点同样 +10%。
- GPT-6 Astra 已在 Bedrock 上架，global 端点与 OpenAI 同价；GPT-6.1 Sol 不在 Bedrock 价目表中。

§2 订阅用满，折合多少 API 美元

下图和下表的「API 等值」取自 SemiAnalysis：把每周额度用满，按 agentic（编码 Agent）负载结构折算成 API 美元。Claude 用官方 API 价，等同于 Bedrock global 端点的价格。

图 1 · 每 $1 月费能换到多少 API 用量

SemiAnalysis，2026-10-05；agentic 负载；柱末标注倍数与每月 API 等值

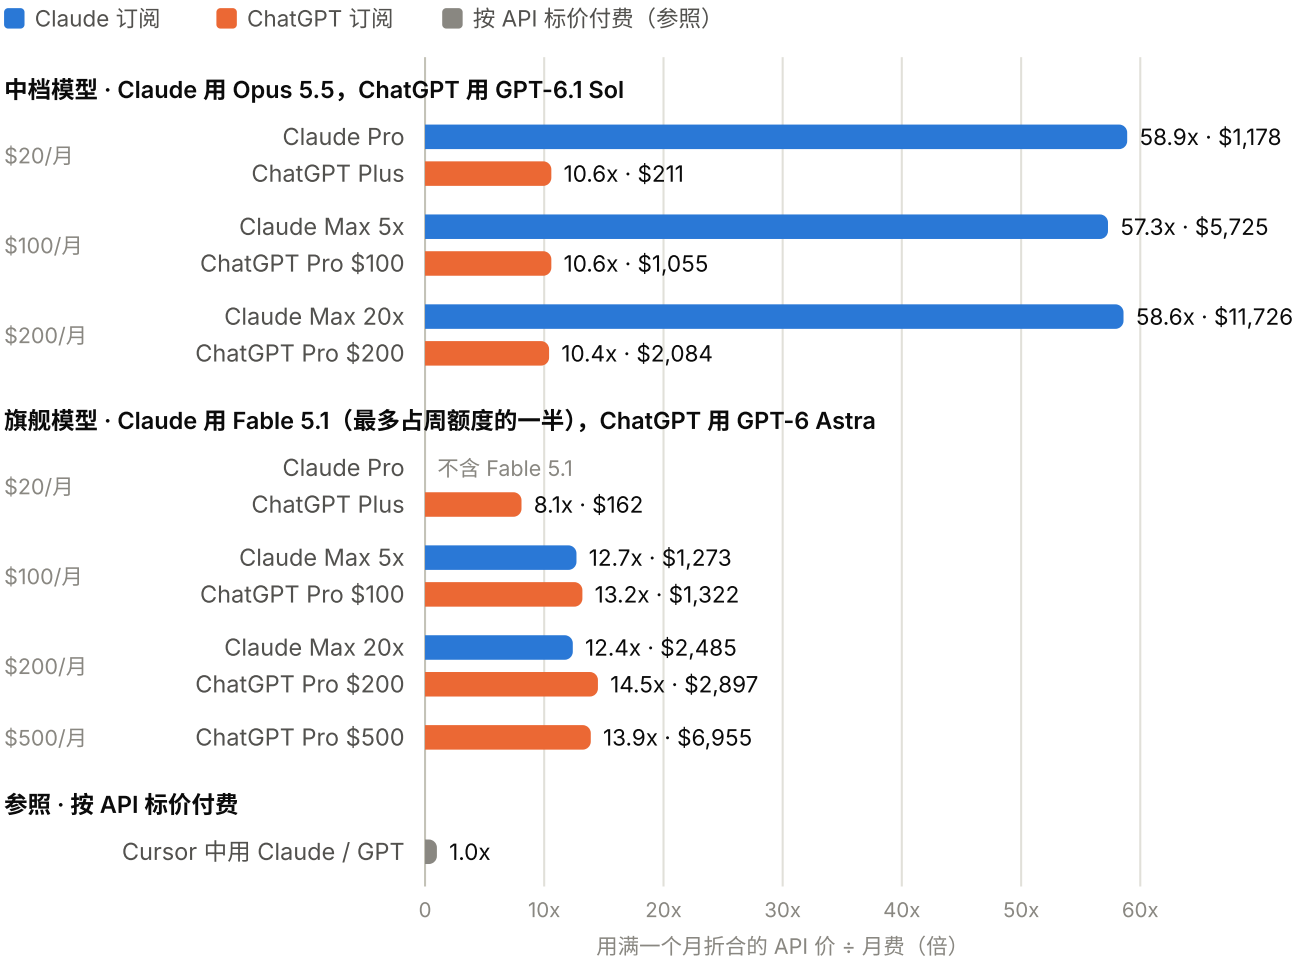


表 3 · Claude 订阅用满（Opus 5.5，agentic 负载）

套餐	月费	API 等值/月（官方 API = Bedrock global）	倍数	Bedrock 区域端点（+10%）	约合 token/月	其中非缓存读
Pro	$20	$1,178	58.9x	$1,296（64.8x）	25–30 亿	0.84–1.0 亿
Max 5x	$100	$5,725	57.3x	$6,298（63.0x）	120–143 亿	4.1–4.9 亿
Max 20x	$200	$11,726	58.6x	$12,899（64.5x）	246–294 亿	8.4–10 亿

表 4 · Claude Max 20x：换用不同模型和负载

模型	agentic 负载	chat 负载
Opus 5.5	$11,726（58.6x）	$9,200（46.0x）
Sonnet 5.5	$12,529（62.6x）[1]	$7,009（35.0x）
Fable 5.1	$2,485（12.4x）[2]	$2,480（12.4x）

- [1] 该数字按 10 月 7 日之前的缓存读价 $0.20 计算。Sonnet 5.5 现价 $0.10，按新价重算约 $8,400–8,900（42–45x，本报告估算）。
- [2] Fable 5.1 最多只能用掉周额度的一半，用到这个上限时还剩一半额度可以给其他模型。Pro 不含 Fable 5.1；Max 5x 用 Fable 5.1 约 $1,273（12.7x）。
- 按周额度算，Max 5x 约为 Pro 的 4.9 倍（$5,725 ÷ $1,178），Max 20x 约为 10 倍；Anthropic 只承诺 5 小时窗口的 5 倍和 20 倍。

表 5 · ChatGPT / Codex 订阅用满（9 月 29 日之后的额度）

套餐	月费	GPT-6.1 Sol API 等值/月	倍数	GPT-6 Astra API 等值/月	倍数
Plus	$20	$211	10.6x	$162	8.1x
Pro $100	$100	$1,055	10.6x	$1,322	13.2x
Pro $200	**$200**	**$2,084**	**10.4x**	**$2,897**	**14.5x**
Pro $500	$500	≈ $5,200（推算[3]）	≈ 10.4x	$6,955	13.9x

表 5b · 同价位对比（中档模型）

月费	Claude（Opus 5.5）	ChatGPT（GPT-6.1 Sol）	Claude ÷ ChatGPT
$20	Pro：$1,178（58.9x）	Plus：$211（10.6x）	5.6 倍
$100	Max 5x：$5,725（57.3x）	Pro $100：$1,055（10.6x）	5.4 倍
$200	Max 20x：$11,726（58.6x）	Pro $200：$2,084（10.4x）	5.6 倍

- [3] SemiAnalysis 测得调整后 Pro $100、$200、$500 三档每美元的 token 数相同，故按 Pro $200 的比例推算。
- 约合 token/月：Pro $200 用 GPT-6.1 Sol 约 79–104 亿（其中非缓存读 2.7–3.6 亿）；用 GPT-6 Astra 约 16–20 亿（非缓存读 0.55–0.67 亿）。
- GPT-6 Astra 走 Bedrock 区域端点：Pro $200 约 $3,187（15.9x），Pro $500 约 $7,651。GPT-6.1 Sol 走 OpenAI 数据驻留端点：Pro $200 约 $2,292。
- OpenAI 官方未公布 Pro 各档相对 Plus 的倍数。Pro $200 的这次下调被普遍报道为从 20 倍降到 10 倍。另有第三方页面称「10 月 29 日起 Pro $100 和 $500 额度翻倍」，OpenAI 官方定价页没有这项内容，本报告未采用。

§3 交叉验证：真实账号实测

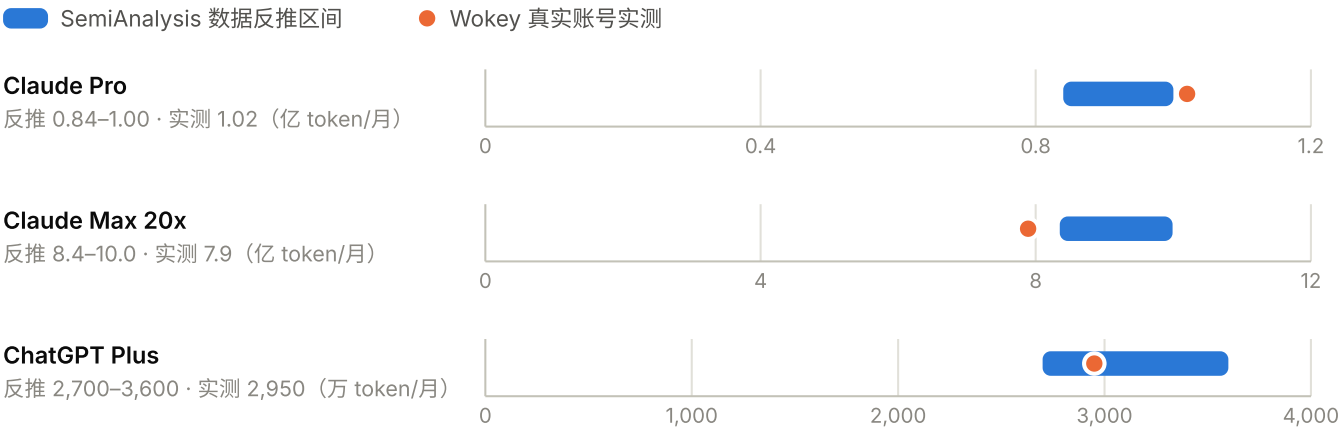
Wokey 用真实订阅账号的流量测算，样本足够的有三个套餐；Max 5x、Pro $100、Pro $200 的样本还不够，未发布数据。

表 6 · Wokey 真实账号实测（2026-10-19 至 10-26 当周；第二行小字为中间一半账号的区间）

套餐	每周 API 等值	折合每月	倍数	每月总 token	其中缓存读	每月非缓存 token	每月输出
Claude Pro 103 个账号	$157 $142–170	≈ $680	34x	6.1 亿	83%	1.0 亿	740 万
Claude Max 20x 21 个账号	$1,602 $1,147–1,745	≈ $6,940	34.7x	90 亿	92%	7.9 亿	5,550 万
ChatGPT Plus（Codex） 12 个账号	$55 $41–58	≈ $238	11.9x	9.3 亿	96%	2,950 万	170 万

图 2 · 每月非缓存 token：两个独立来源几乎一致

蓝色区间：用 SemiAnalysis 的 API 等值和负载结构反推；橙点：Wokey 实测（每周值 × 52/12）。每行的刻度不同。



两个来源在美元上差距不小（Claude 59 倍对 34 倍），但在「非缓存 token」上差距只在约 20% 以内。美元上的差距主要有两个原因：

- 缓存读占比不同。SemiAnalysis 的 agentic 负载有 96.6% 是缓存读，真实流量只有 83–92%。缓存读几乎不占订阅额度，却按 API 价计入美元。
- 真实用户会混用多个模型。Wokey 测得 Opus 5.5 每个 token 占用的额度只有其他 Opus / Fable 模型的约 0.6 倍；只用 Opus 5.5 能拿到更多 token，混用时折算的美元就少。

结论：订阅真正限制的是非缓存 token。Claude Pro 约 1 亿/月，Max 20x 约 8–10 亿，ChatGPT Plus 约 3,000 万。

§4 倍数从哪来：缓存读

表 7 · SemiAnalysis 使用的两种负载结构（各类 token 占全部 token 的比例）

负载	新输入	缓存读	缓存写	输出
agentic（编码 Agent）	0.4%	96.6%	2.6%	0.3%
chat（聊天）	2%	75%	13%	10%

- **订阅几乎不按缓存读计额度。**SemiAnalysis 灌入 5 亿缓存读 token 后计量条仍不动；Wokey 对 Claude 的实测也显示：缓存写占用的额度与普通输入差不多，缓存读几乎不占，输出占用约为输入的 4–7 倍。
- **API 对缓存读照样收费。**编码 Agent 绝大部分 token 是缓存读，于是同样一份用量，订阅几乎不扣额度，API 却要收将近一半的钱（图 3）。

图 3 ·Claude Pro 用满时：token 数量占比 vs 折合 API 金额占比

缓存读占 token 的 96.6%，只占 API 金额的约一半；输出只占 token 的 0.3%，却占金额的 15%。窄条上的数值见下表。



Claude Pro 用满（Opus 5.5，agentic）	缓存读	缓存写	输出	新输入
token 数量占比	96.6%	2.6%	0.3%	0.4%
折合 API 金额占比（5 分钟缓存写）	48.4%	32.6%	15.0%	4.0%
折合 API 金额占比（1 小时缓存写）	40.5%	43.6%	12.6%	3.4%

- **所以负载越偏 Agent 越划算。**Max 20x 用 Opus 5.5 时，agentic 负载是 58.6 倍，chat 负载只有 46.0 倍（表 4）。
- **补贴力度因模型而异。**SemiAnalysis 估算（假设 API 毛利 92%）：用户把 Opus 5.5 用满时，Anthropic 在这个订阅上的毛利约 −369%；把 Fable 5.1 用满时约 1%。 按平均 20% 的使用率，两者分别约为 6% 和 80%。订阅约占 Anthropic 收入的 10%，却占用 40% 以上的推理算力。

§5 其他订阅

表 8 · 其他订阅

产品	价格	用 Claude / GPT 的倍数	说明
Cursor（Plus / Premium / Super / Ultra）	$8 / $30 / $100 / $200	**1x**	订阅额度只覆盖 Cursor / Grok 自家模型；Opus 5.5、GPT-6.x 等第三方模型不含额度，按 API 标价计费。Teams / Enterprise 每百万 token 另加 $0.25
中国厂商 coding plan（GLM / Kimi / MiniMax 等）	见下	平均略低于 12x	SemiAnalysis：档位越高越划算；分厂商、分模型的数据在付费墙后
MiniMax M Plan（原 Token Plan，10 月 15 日更名）	Go $22 / Explore $55 / Build $132	—	唯一直接按 token 给额度：更名前约 17 亿 / 51 亿 / 125 亿 token/月；新档位为 Go 的 1 / 3 / 7.5 倍。倍数取决于缓存占比，无可靠实测
智谱 GLM Coding Plan	Lite $18 / Pro $80 / Max $168	—	按 credits：每 5 小时 2,000 / 12,000 / 28,000；每周 1 万 / 6 万 / 14 万
Kimi 会员（含 Kimi Code）	¥99 / ¥199 / ¥699	—	5 小时滚动窗口；Pro 为 4 倍、Max 为 14 倍 Agent 额度
阿里 Qwen（百炼）	¥39 / ¥139 / ¥499	—	每月 11,500 / 45,000 / 180,000 credits
Google AI Pro / Ultra	$19.99 / $99.99 / $199.99	未知	不公布额度，也没有可靠实测

中国厂商的价格和额度取自第三方汇总站 codingplan.org（2026-09-24 更新）和 usagepricing.com，以各家官网为准。

§6 局限与注意事项

- **都是第三方实测，而且会变。**厂商不公布额度，会悄悄调整，也会做 A/B 测试：SemiAnalysis 发现三个配置相同的账号里，有一个的额度低约 20%。关键时间点见附录 B。
- **「API 等值」是上限，不是实际能省下的钱。**它假设每周都把额度用满，而且改用 API 后还会用同样多的 token。
- **负载结构决定倍数。**SemiAnalysis 的 agentic 结构（96.6% 缓存读）对订阅最有利；你的实际缓存读占比越低，倍数越接近 Wokey 的 34 倍。
- **没有纳入比较的因素：**Batch API（五折）不适合交互式编码；企业私有折扣（Bedrock private offer、EDP 等）会进一步降低 API 侧成本。

附录 A 换算方法

加权单价 = Σ（各类 token 占比 × 该类单价）。下表按表 7 的负载结构和表 1、表 2 的单价计算；短 TTL 指 5 分钟（Claude）或 30 分钟（OpenAI）缓存写，长 TTL 指 1 小时或 12 小时。

表 A1 · 加权单价（美元 / 百万 token）

模型 / 渠道	agentic（短 TTL 缓存写）	agentic（长 TTL 缓存写）	chat（短 TTL）	chat（长 TTL）
Opus 5.5：官方 API = Bedrock global	$0.399	$0.477	$2.880	$3.270
Opus 5.5：Bedrock 区域端点	$0.439	$0.525	$3.168	$3.597
GPT-6.1 Sol：OpenAI API	$0.200	$0.265	$1.440	$1.765
GPT-6 Astra：OpenAI API	$1.481	$1.806	$7.575	$9.200

- 约合 token/月 = API 等值 ÷ 加权单价；非缓存读 = 约合 token/月 × (1 − 缓存读占比)。例：Claude Pro $1,178 ÷ $0.399 ≈ 29.5 亿（短 TTL），÷ $0.477 ≈ 24.7 亿（长 TTL）。
- Wokey 的每周值 × 52/12 ≈ 4.33 折算成每月。

用自己的数据算（Opus 5.5，Bedrock global = 官方 API）

```
月成本（美元）= 新输入 × 4 + 5 分钟缓存写 × 5 + 1 小时缓存写 × 8 + 缓存读 × 0.20 + 输出 × 20
                （各项单位：百万 token）
Bedrock 区域端点：再 × 1.1
倍数 = 月成本 ÷ 月费
```

四类 token 的用量可以从 Claude Code 的本地会话日志取：每条请求都带 `input_tokens`、`cache_creation_input_tokens`、`cache_read_input_tokens`、`output_tokens` 四个字段，ccusage 这类工具会直接按 API 价汇总。

附录 B 时间线

表 B1 · 关键时间点（2026 年）

日期	事件
9 月 13 日	Claude Code 夏季活动（周额度 +50%）结束
9 月 22 日	Opus 5.5 发布；Anthropic 提高 Pro / Max / Team 的 5 小时额度（Opus：Pro 约 +50%，Max 约 +20%）
9 月 29 日	OpenAI 下调新订阅 Pro $200 的额度，新增 Pro $500 档
10 月 5 日	SemiAnalysis 报告发布（本报告的主要数据来源）
10 月 7 日	Sonnet 5.5 缓存读降价 50%（$0.20 → $0.10）
10 月 12 日	AWS Bedrock 价目表版本（本报告所用）
10 月 15 日	MiniMax Token Plan 更名为 M Plan
10 月 19–26 日	Wokey 测量周（本报告所用）
10 月 29 日	Pro $200 老用户的旧额度到期
10 月 30 日	所有 Pro $200 订阅按新额度；本报告数据截止

附录 C 来源

1. Anthropic 官方定价：https://platform.claude.com/docs/en/about-claude/pricing
2. AWS Bedrock 公开价目（Price List API，us-east-1，2026-10-12 版）：https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/AmazonBedrockFoundationModels/current/us-east-1/index.json
3. AWS Bedrock 定价页：https://aws.amazon.com/bedrock/pricing/
4. OpenAI API 定价：https://developers.openai.com/api/docs/pricing
5. ChatGPT / Codex 套餐与 credit 费率：https://learn.chatgpt.com/docs/pricing
6. SemiAnalysis 原文（付费墙）：https://newsletter.semianalysis.com/p/anthropic-subscriptions-offer-5x
7. SemiAnalysis 数据公开转述：explainx：https://explainx.ai/blog/semianalysis-claude-vs-chatgpt-subscription-api-value-limit-testing-2026
8. SemiAnalysis 数据公开转述：1023jack：https://1023jack.com/market/the-5x-is-a-subsidy-not-a-price-what-semianalysis-found-inside-ai-subscriptions/
9. SemiAnalysis 数据公开转述：Implicator：https://www.implicator.ai/claude-opus-plans-5x-openai-sol-api-value/
10. Wokey：Claude 额度实测：https://wokey.ai/claude-usage-limits
11. Wokey：Codex 额度实测：https://wokey.ai/codex-usage-limits
12. Codex Pro $200 额度下调：https://apidog.com/blog/codex-pro-limit-cut-october-30/
13. Codex 额度与 credit 汇总：https://simplemetrics.xyz/chatgpt-codex-limits-2026/
14. Cursor 定价页：https://cursor.com/pricing
15. Cursor 计费文档：https://cursor.com/docs/account/pricing
16. 中国厂商 coding plan 汇总（codingplan.org，2026-09-24 更新）：https://codingplan.org/en
17. MiniMax M Plan 更名记录：https://www.usagepricing.com/blueprint/activity/minimax-2026-10-15-m-plan-replaces-token-plan